Brecha rural–urbana en Saber 11 (2020–2)

IDENTIFICACIÓN DE FACTORES EXPLICATIVOS MEDIANTE APRENDIZAJE AUTOMÁTICO

Juan Manuel Vellaizan · María Paula Orozco · Valery Nayuni Ccaulla · Nicolás Orduña
Inteligencia Artificial con Aplicaciones en Economía I · Universidad Externado de Colombia

OBJETIVO DE LA ETAPA 2

Pasar de describir la brecha a explicarla. Con los 449.695 estudiantes que respondieron el cuestionario socioeconómico estimamos modelos que predicen el puntaje global y el riesgo de bajo desempeño.
Con esos modelos medimos cuánto aporta cada factor a la brecha de 28,2 puntos entre colegios urbanos y rurales, y qué estudiantes y territorios tienen mayor riesgo.



PREPARACIÓN DE LOS DATOS

Antes de entrenar, los datos se dividen y se transforman con un pipeline de scikit-learn. Todo el preprocesamiento se ajusta solo con el entrenamiento, para que ninguna información de la prueba se filtre al modelo (sin fuga de información).
Se excluyen como predictores los puntajes por área y la modalidad «Excelencia» de Generación E, porque se derivan del resultado.

01

Partición 80/20 por sede: 357.481 estudiantes para entrenar y 92.214 para probar, en colegios que el modelo nunca vio.

02

ColumnTransformer: dummies con categoría de referencia, recorte de extremos y mediana con indicador de faltante. 34 variables → 101 columnas.

03

Índice de bienes con PCA sobre seis bienes estandarizados (32 % de la varianza). Ninguna columna tiene un VIF mayor que 10.

MODELOS DE LA ETAPA

La pregunta de la etapa combina tres tipos de problema, y cada uno define qué modelos usar.
La regresión es el modelo principal: mide cuánto explica el contexto. La clasificación sirve para focalizar y el agrupamiento muestra que la ruralidad no es homogénea. Todo se implementó en scikit-learn.

01

Regresión del puntaje global: lineal, Ridge, Lasso, Random Forest y Gradient Boosting, frente a dos líneas base.

02

Clasificación del bajo desempeño (puntaje menor que 216, el percentil 25): regresión logística y Gradient Boosting.

03

Agrupamiento: K-means sobre 2.620 sedes rurales oficiales, con 12 indicadores estandarizados.

EVALUACIÓN E INTERPRETACIÓN

01

Validación cruzada GroupKFold agrupada por sede. Los hiperparámetros se eligen con GridSearchCV y búsquedas en rejilla sobre el 35 % de las sedes de entrenamiento; la prueba se usa solo al final.

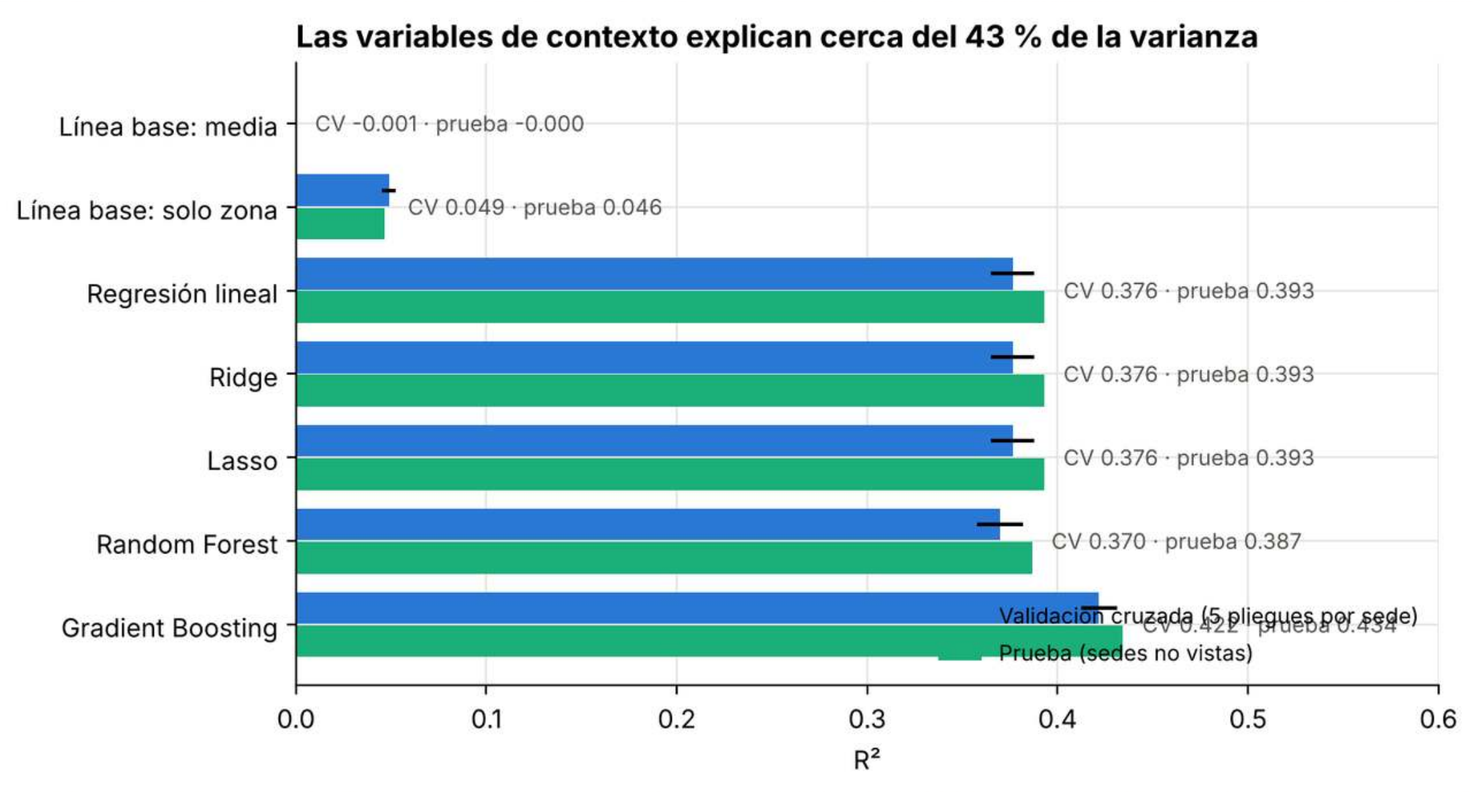
02

Clases desbalanceadas (25 % positivas): class_weight="balanced" y sin exactitud. Se reportan ROC-AUC, PR-AUC, precisión, recall y F1, con el umbral elegido en predicciones fuera de muestra del entrenamiento.

03

Interpretación: MCO con errores agrupados por sede, Oaxaca-Blinder, Shapley por grupos, importancia por permutación, dependencia parcial y escenarios. XGBoost y SHAP no se pudieron instalar: se usó HistGradientBoosting.

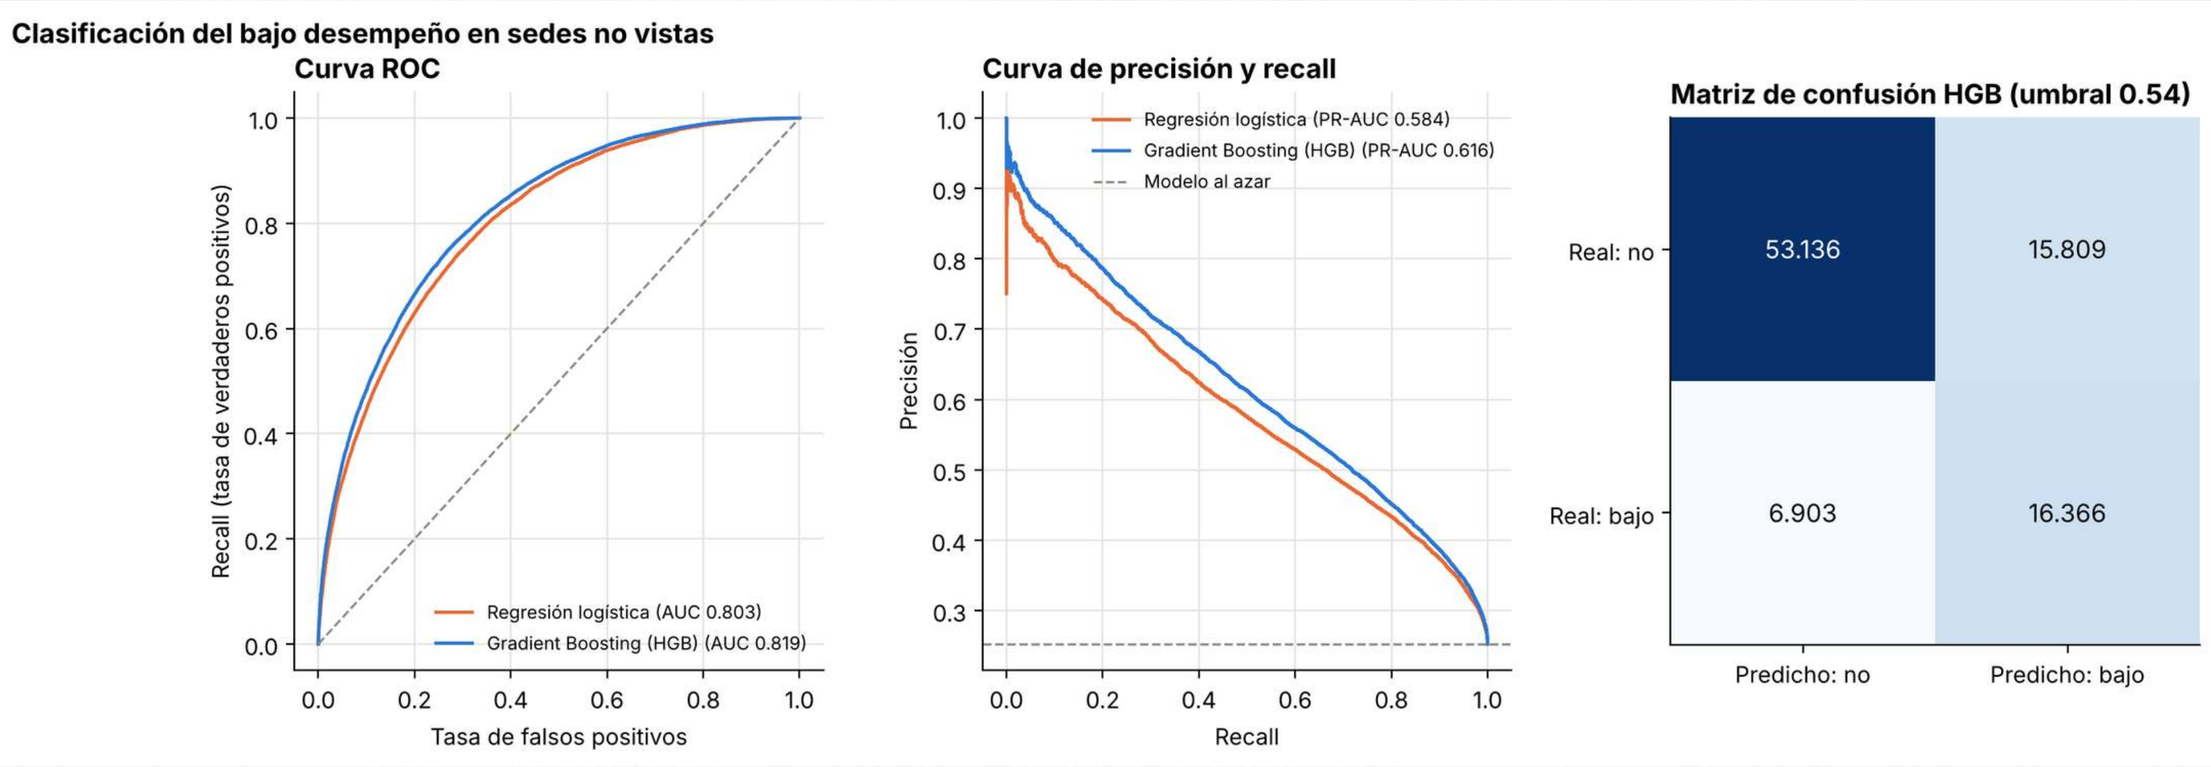
Resultados de la regresión



Gráfica G7. R^2 en validación cruzada (5 pliegues por sede) y en prueba.

- La zona sola explica menos del 5 % del puntaje (R^2 = 0,046).
- El Gradient Boosting es el mejor modelo: R^2 = 0,434 y RMSE = 36,6 puntos en sedes no vistas.
- Ridge y Lasso igualan a la regresión lineal (R^2 = 0,393): Lasso no elimina ninguna de las 101 columnas.
- Sobreajuste mínimo: R^2 de 0,448 en entrenamiento y 0,434 en prueba.
- Sin sesgo por zona: residuo medio rural de −1,1 puntos.

Clasificación del bajo desempeño



Desempeño: el Gradient Boosting logra ROC-AUC = 0,819 y PR-AUC = 0,616, más del doble del azar (0,25); la logística, 0,803 y 0,584.

Umbral de máximo F1 (0,54): recall 70 % y precisión 51 %. Con el umbral de 0,45, el recall sube a 81 %.

Sesgo: marca al 67 % de los rurales frente al 43,5 % real. Para focalizar conviene ordenar por probabilidad.

APORTE DE LAS VARIABLES NUEVAS

01

Regresión lineal
R^2: 0,361 → 0,393

13 variables construidas con 15 columnas que no se usaban

Misma partición, hiperparámetros y validación en ambos casos

02

Gradient Boosting
R^2: 0,397 → 0,434

Cerca de 9 % más varianza explicada

RMSE de 37,8 a 36,6 puntos; igual mejora en validación cruzada

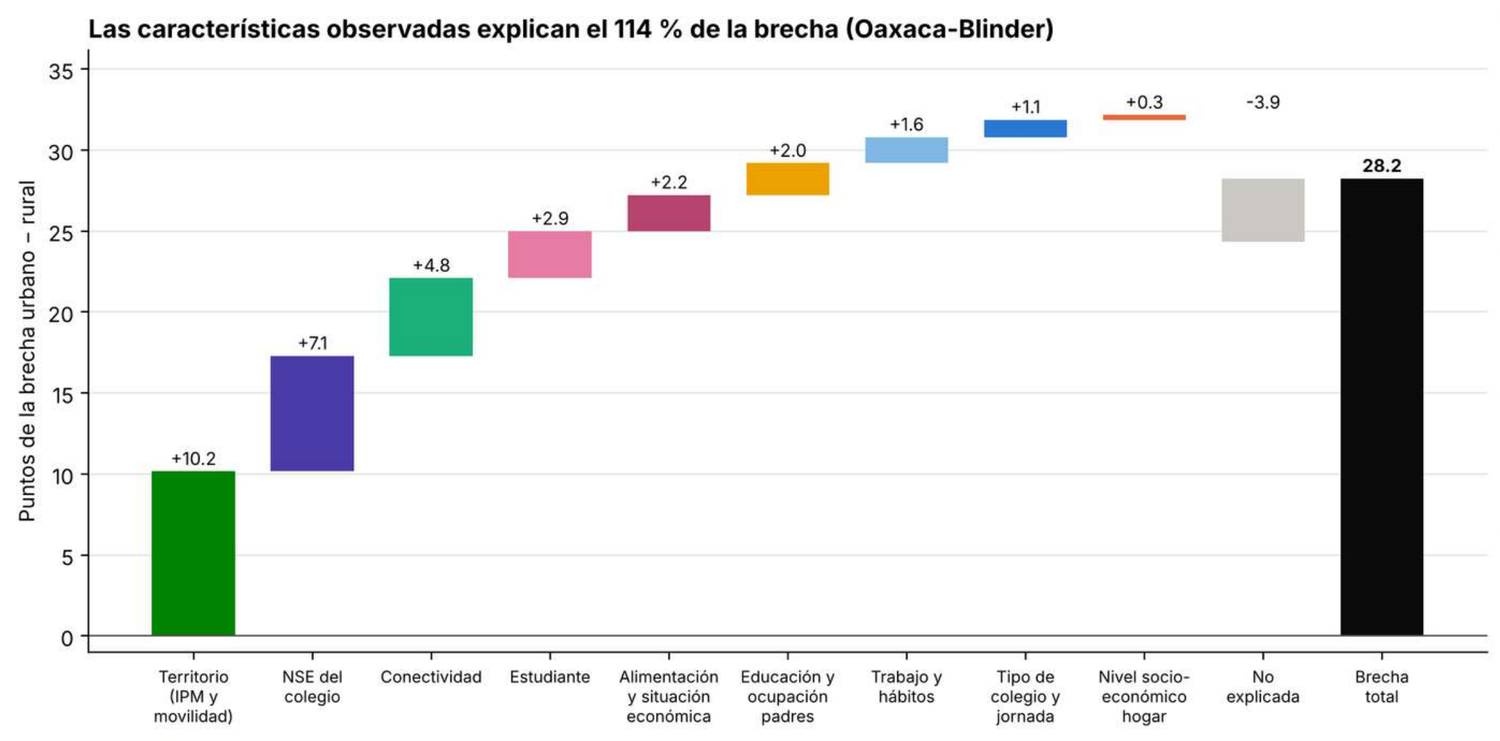
03

Clasificación (HGB)
PR-AUC: 0,590 → 0,616

Más aportan: lectura por gusto y situación económica

Luego: alimentación, uso de internet y ocupación de los padres

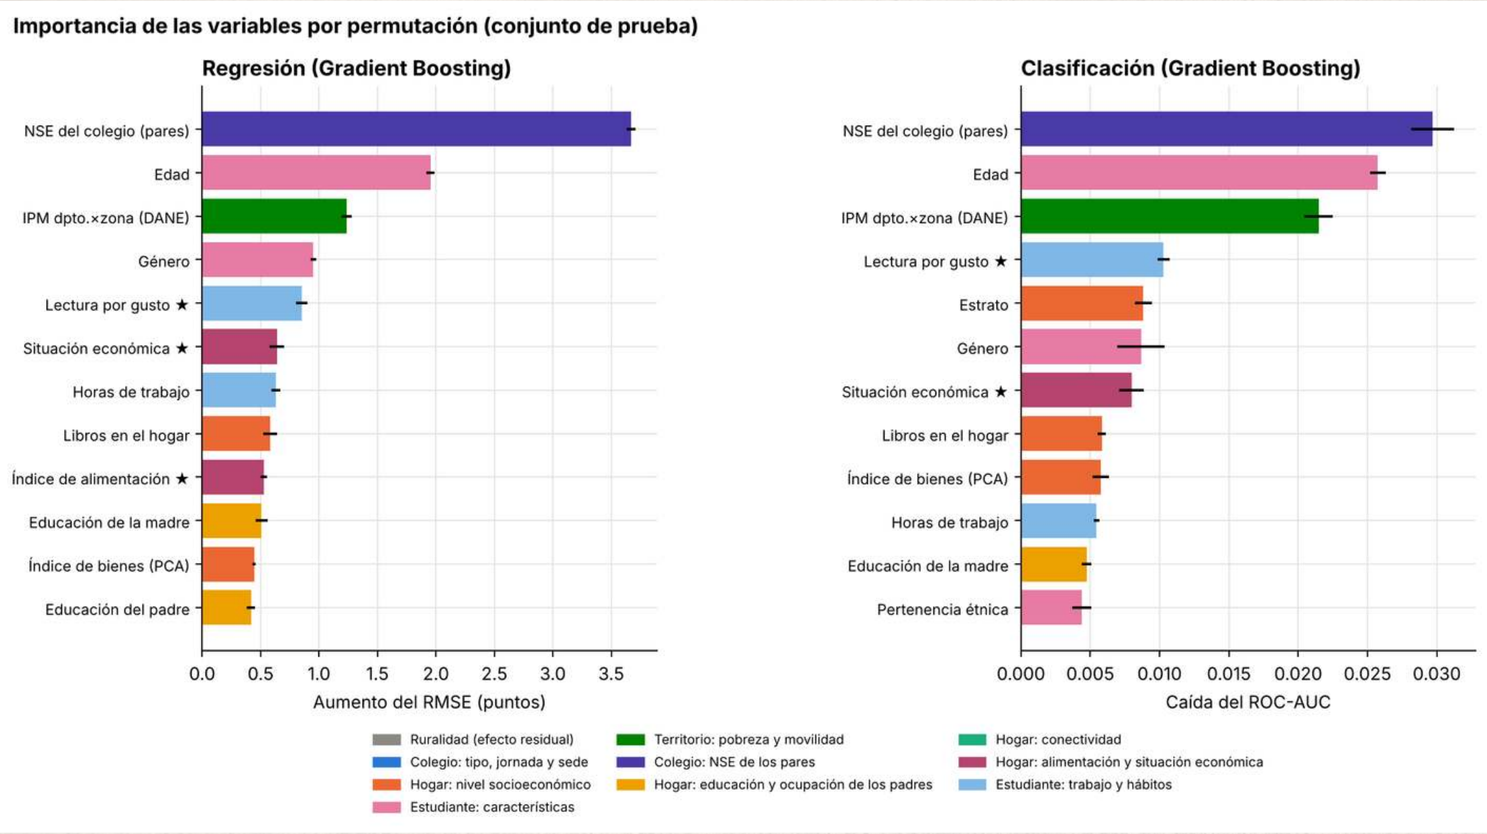
¿Qué explica la brecha? Oaxaca-Blinder



Gráfica G9. Aporte de cada grupo de factores a la brecha urbano − rural (puntos). Intervalos por bootstrap de 50 réplicas por sede.

- Coeficiente rural (MCO con errores por sede): +3,9 puntos (IC 95 %: 2,4 a 5,4). Con iguales características, los rurales obtienen algo más.
- Las características explican 32,2 de los 28,2 puntos: 114 %.
- Territorio 10,2 (36 %) · NSE del colegio 7,1 (25 %) · Conectividad 4,8 (17 %) · Alimentación y situación económica 2,2 (8 %).
- Robusto: entre 112 % y 115 % con otras referencias.

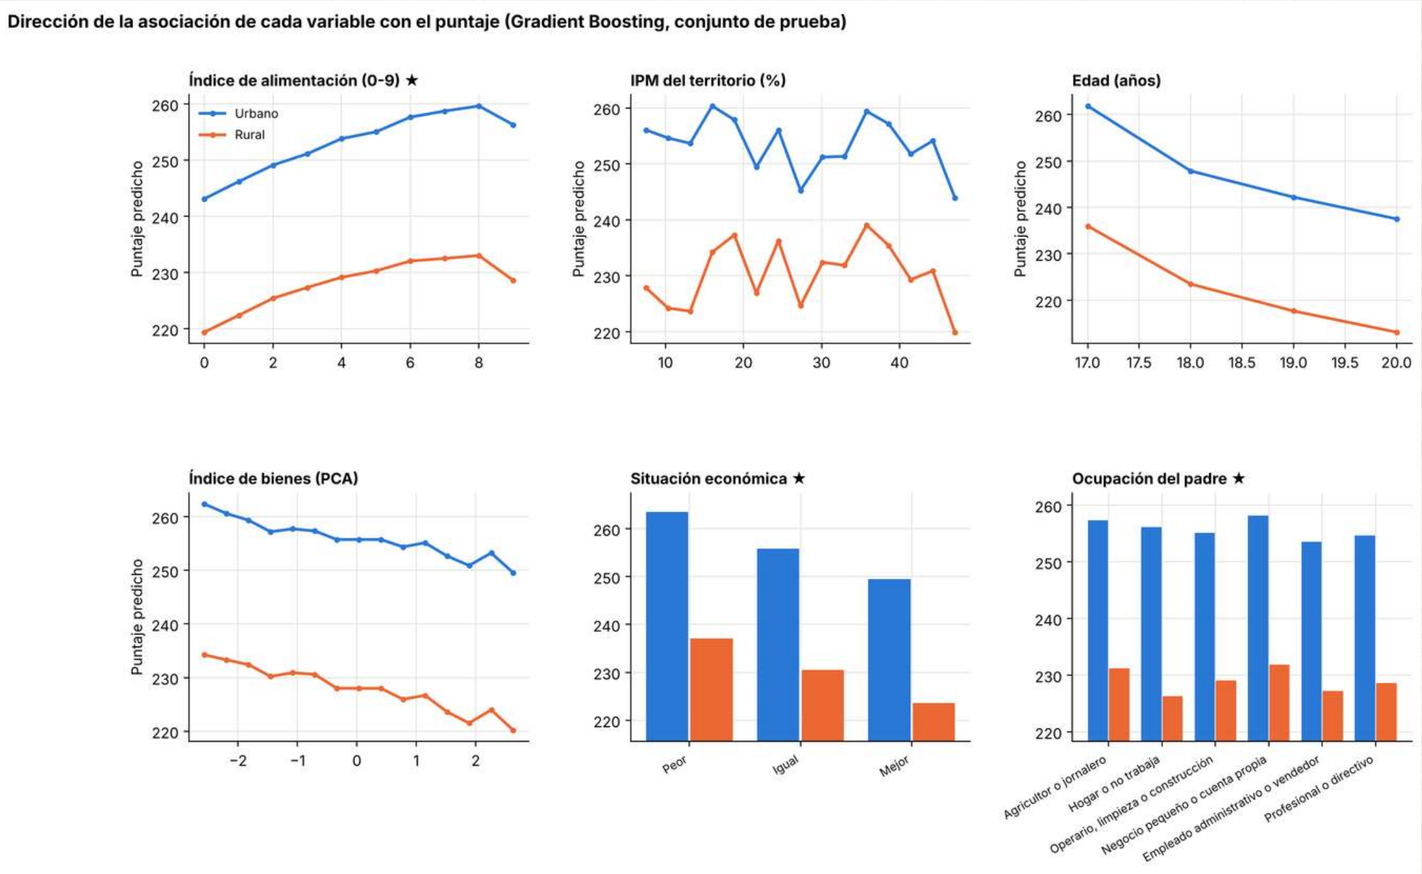
Importancia de las variables y Shapley



Gráfica G10. Aumento del RMSE (regresión) y caída del ROC-AUC (clasificación) al permutar cada variable.

- Dominan el NSE del colegio, la edad y el IPM del territorio. La edad capta la extraedad: repitencias y entradas tardías acumuladas.
- Tres variables nuevas (★) están entre las diez primeras: lectura por gusto, situación económica y alimentación.
- La zona rural no aparece: conocido el contexto, la ubicación no aporta.
- Shapley (Gradient Boosting) coincide con Oaxaca: colegio 7,1, conectividad 4,8 y alimentación 2,0 puntos.

Dirección de los efectos: hallazgos



Gráfica G11. Puntaje predicho al mover cada variable con todo lo demás constante. Azul: urbanos; naranja: rurales.

- Situación económica ★: quienes reportan que su hogar empeoró obtienen 8,2 puntos más que quienes siguen igual, aun con todos los controles. Parece medir el choque de la pandemia, no la pobreza.
- Ocupación del padre ★: a igual educación e ingreso, ser hijo de agricultor no es una desventaja.
- Alimentación ★: del índice 0 al 8, el puntaje predicho sube entre 14 y 17 puntos en ambas zonas.
- Edad: cada año de extraedad, cerca de 8 puntos menos.

HALLAZGOS CLAVE

01 No es la ruralidad: con iguales características, los rurales obtienen +3,9 puntos.

02 Territorio y NSE del colegio explican 17,3 de los 28,2 puntos de la brecha.

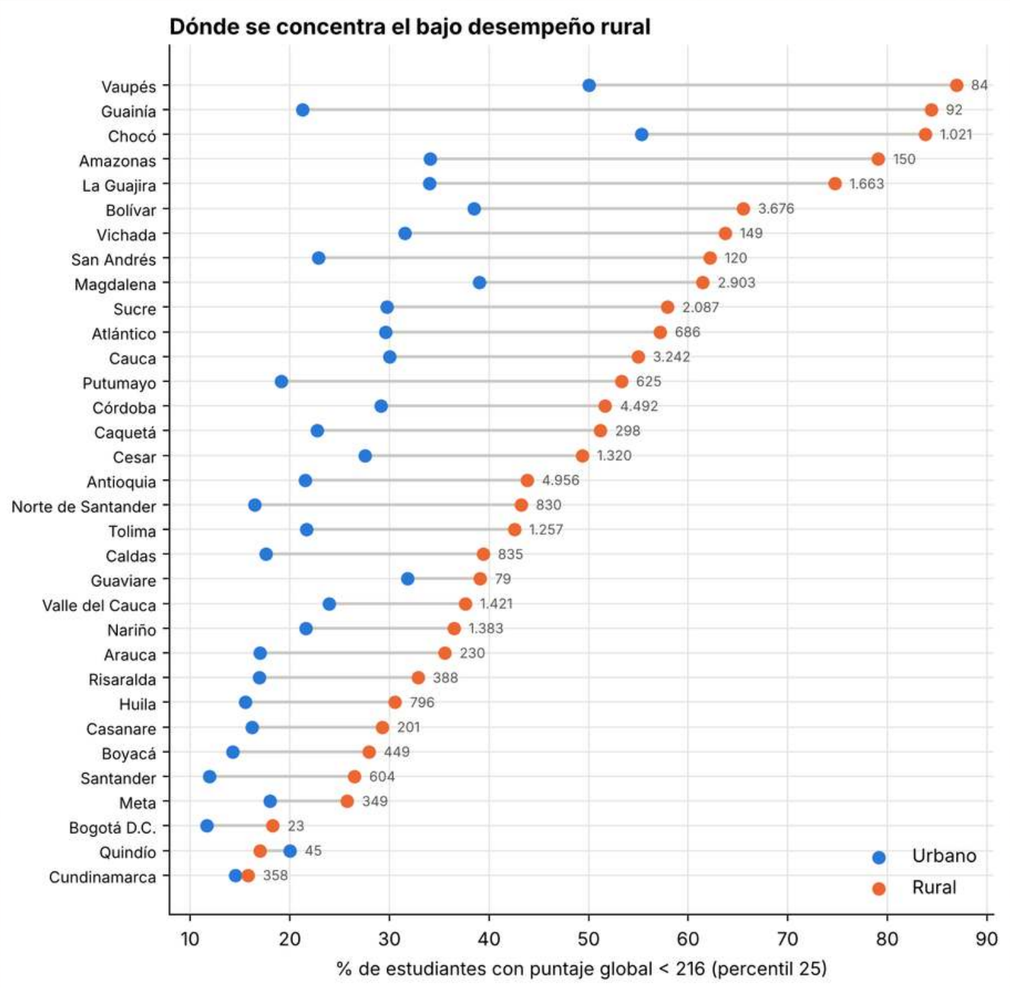
03 Conectividad: 4,8 puntos. Importa el uso efectivo de internet, no solo tenerlo.

04 Paradoja: los hogares que empeoraron frente al año anterior obtienen 8,2 puntos más.

05 Hijos de agricultores: sin desventaja a igual educación e ingreso del hogar.

06 Sedes más pobres: solo 29 % focalizado por Sisbén y 88 % étnico.

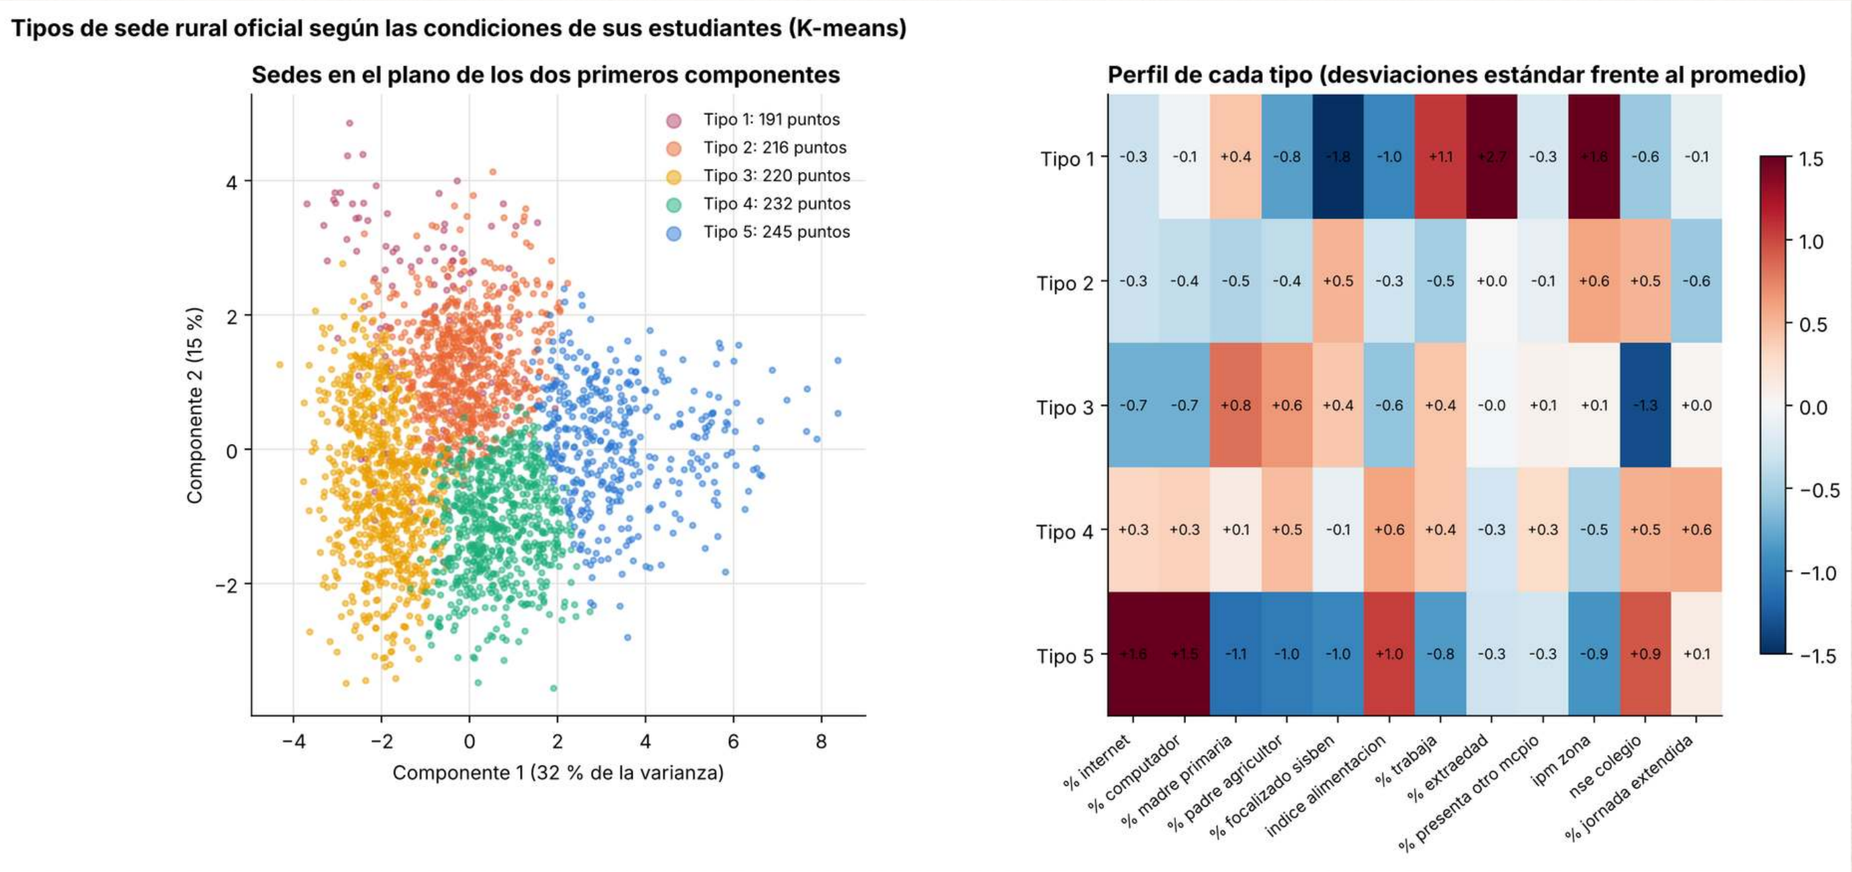
Focalización y escenarios



- Probabilidades de riesgo fuera de muestra para todos los estudiantes (ROC-AUC = 0,815).
- Por tasa: Vaupés, Guainía, Chocó, Amazonas y La Guajira, con 75 % a 87 % de sus rurales bajo el percentil 25.
- Por volumen: Antioquia (unos 5.000 rurales en riesgo alto), Córdoba, Bolívar, Cauca y Magdalena.
- Municipios prioritarios: Uribia, Manaure y Maicao (La Guajira).
- Escenario: internet y computador para todos los rurales cerraría entre 16 % y 23 % de la brecha; alimentación en la mediana urbana, cerca de 5 %.

Gráfica G12. % de estudiantes con bajo desempeño por departamento y zona; el número es la cantidad de rurales en riesgo alto.

Tipología de sedes rurales oficiales (K-means)



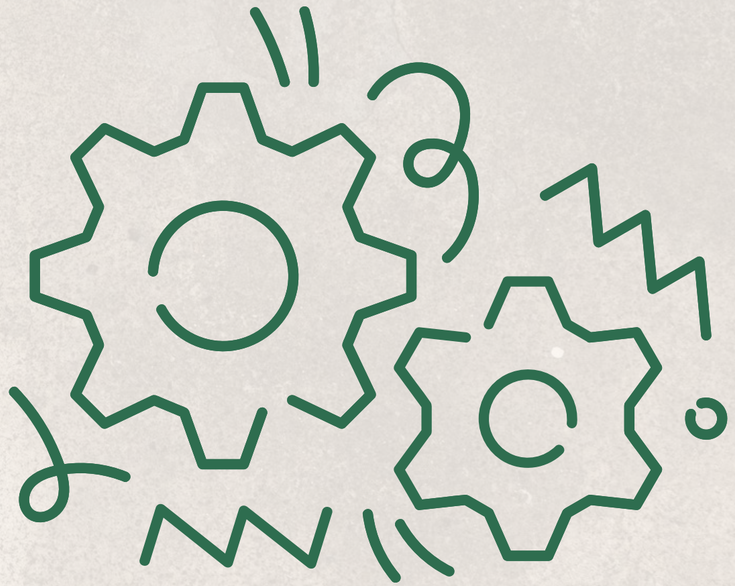
2.620 sedes, 12 indicadores estandarizados. Silueta menor que 0,2: las sedes forman un continuo; entre 3 y 8 grupos, k = 5 es la mejor opción.

54 puntos entre el tipo 1 (191, pobreza extrema) y el tipo 5 (245, rural conectada): casi el doble de la brecha rural-urbana.

Tipo 1: solo 29 % focalizado por Sisbén y 88 % étnico. Posible error de exclusión en la focalización.

QUÉ RECOMENDAMOS

1. Conectividad focalizada en las sedes de los tipos 2 y 3, donde menos de una cuarta parte de los estudiantes tiene internet: es la palanca más robusta (cerraría entre 16 % y 23 % de la brecha).
2. Alimentación escolar y nivelación por edad en las sedes del tipo 1, que combinan la peor alimentación, la extraedad y el trabajo.
3. Focalización que combine el Sisbén con las probabilidades de riesgo del modelo y los censos indígenas.



CONCLUSIONES

La brecha de 28 puntos no se debe a la ruralidad: las diferencias de composición explican el 114 % de ella. El territorio, el nivel socioeconómico del colegio, la conectividad y la alimentación son los factores con mayor aporte, y Oaxaca-Blinder y Shapley coinciden. Las 13 variables incorporadas mejoraron todos los modelos.

MUCHAS GRACIAS POR LA ATENCIÓN

github.com/JuanAlbizari/Proyecto-la-septimo-semestre